

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

Кафедра: КБ-4 «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта»

Лабораторная работа №1 по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Выполнил:

Картунчиков А. М.

Группа:

ББМО-01-23

Скопируем проект по ссылке в локальную среду выполнения

```
[1] !git clone https://github.com/ewatson2/EEL6812_DeepFool_Project.git
```

Сменим директорию исполнения на вновь созданную папку

"EEL6812 DeepFool Project" проекта

```
[2] %cd /content/EEL6812_DeepFool_Project

/content/EEL6812_DeepFool_Project
```

Выполним импорт библиотек

```
[3] import numpy as np
    import json, torch
    from torch.utils.data import DataLoader, random_split
    from torchvision import datasets, models
    from torchvision.transforms import transforms

from models.project models import FC_500_150, LeNet_CIFAR, LeNet_MNIST, Net
    from utils.project utils import get_clip_bounds, evaluate_attack, display_attack

[4] from google.colab import drive
    drive.mount('/content/drive')

A Mounted at /content/drive
```

Установим случайное рандомное значение в виде переменной rand_seed для варианта 14

```
rand_seed={"14"}
```

Используем в качестве устройства видеокарту

```
device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")
```

Загрузим датасет MNIST с параметрами mnist_mean = 0.5, mnist_std = 0.5, mnist_dim = 28

```
mist_mean = 0.5
mist_dim = 28

[7] device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")

[8] mist_min, mnist_max = get_clip_bounds(mnist_mean, mnist_std, mnist_dim)
mnist_min = mnist_min.to(device)
mnist_max = mnist_max.to(device)
mnist_tf = transforms.Compose([ transforms.ToTensor(), transforms.Normalize( mean=mnist_mean, std=mnist_std)])
mnist_tf_train = transforms.Compose([ transforms.RandomHorizontalFlip(), transforms.ToTensor(), transforms.Normalize( mean=mnist_mean, std=mnist_mist_tf_inv = transforms.Compose([ transforms.Normalize( mean=0.0, std=np.divide(1.0, mnist_std)), transforms.Normalize( mean=np.multiply(-1.6 mnist_temp = datasets.MNIST(root='datasets/mnist', train=True, download=True, transform=mnist_tf_train)
mnist_train, mnist_val = random_split(mnist_temp, [50000, 10000])
mnist_test = datasets.MNIST(root='datasets/mnist', train=False, download=True, transform=mnist_tf)

Downloading http://yann.lecun.com/exdb/mnist/train-images-idx3-ubyte.gz
Failed to download (trying next):

suplemen general [5015] (FSPITIST/STATE VERTEX FATISD) contificate venifor faileds contificate be evaluated (scl c:1007).
```

Загрузим датасет CIFAR-10 с параметрами cifar_mean = [0.491, 0.482, 0.447] cifar_std = [0.202, 0.199, 0.201] cifar_dim

```
cifar_mean = [0.491, 0.482, 0.447]

cifar_std = [0.202, 0.199, 0.201]

cifar_dim = 32

[10] cifar_min, cifar_max = get_clip_bounds(cifar_mean, cifar_std, cifar_dim)

cifar_min = cifar_min.to(device)

cifar_tf = transforms.Compose([ transforms.ToTensor(), transforms.Normalize( mean=cifar_mean, std=cifar_std)])

cifar_tf_train = transforms.Compose([ transforms.RandomCrop( size=cifar_dim, padding=4),transforms.RandomHorizontalFlip(), transforms.ToTensor(

cifar_tf_inv = transforms.Compose([ transforms.Normalize( mean=[0.0, 0.0, 0.0], std=np.divide(1.0,cifar_std)), transforms.Normalize( mean=np.ms

cifar_temp = datasets.CIFAR10(root='datasets/cifar-10', train=True, download=True, transform=cifar_tf_train)

cifar_train, cifar_val = random_split(cifar_temp, [40000, 10000])

cifar_test = datasets.CIFAR10(root='datasets/cifar-10', train=False, download=True, transform=cifar_tf)

cifar_classes = ['airplane', 'automobile', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truck']

Downloading https://mea.cs.toronto.edu/-kriz/cifar=10-python.tar.gz to datasets/cifar-10/cifar-10-python.tar.gz

invalidation = 1/200/170M [0e:04/00:06, 40.290/5]

Extracting datasets/cifar-10/cifar-10-python.tar.gz to datasets/cifar-10

Files already downloaded and verified
```

Выполним настройку и загрузку DataLoader batch size = 64 workers = 4

```
[11] batch_size = 64
    workers = 4

[12] mnist_loader_train = DataLoader(mnist_train, batch_size=batch_size, shuffle=True, num_workers=workers)
    mnist_loader_val = DataLoader(mnist_val, batch_size=batch_size, shuffle=False, num_workers=workers)
    mnist_loader_test = DataLoader(mnist_test, batch_size=batch_size, shuffle=False, num_workers=workers)
    cifar_loader_train = DataLoader(cifar_train, batch_size=batch_size, shuffle=False, num_workers=workers)
    cifar_loader_val = DataLoader(cifar_val, batch_size=batch_size, shuffle=False, num_workers=workers)
    cifar_loader_test = DataLoader(cifar_test, batch_size=batch_size, shuffle=False, num_workers=workers)

12    /usr/local/lib/python3.10/dist-packages/torch/utils/data/dataloader.py:617: UserWarning: This DataLoader will create of warnings.warn(
```

Загрузим и оценим стойкость модели Network-In-Network Model к FGSM и DeepFool атакам на основе датасета CIFAR-10

```
fgsm_eps = 0.2
model = Net().to(device)
model.load_state_dict(torch.load('weights/clean/cifar_nin.pth',map_location=torch.device('cpu')))
evaluate_attack('cifar_nin_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max,fgsm_eps, is_fgsm=True)
print('someprint')
evaluate_attack('cifar_nin_deepfool.csv', 'results', device, model,cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)
if device.type == 'cuda': torch.cuda.empty_cache()
```

Загрузим и оценим стойкость модели LeNet к FGSM и DeepFool атакам на основе датасета CIFAR-10

```
model = LeNet_CIFAR().to(device)

model.load_state_dict(torch.load('weights/clean/cifar_lenet.pth', map_location-torch.device('cpu')))

evaluate_attack('cifar_lenet_fgsm.csv', 'results', device, model, cifar_loader_test, cifar_min, cifar_max,
fgsm_eps, is_fgsm=True)

print('')

evaluate_attack('cifar_lenet_deepfool.csv', 'results', device, model,cifar_loader_test, cifar_min, cifar_max, deep_args, is_fgsm=False)

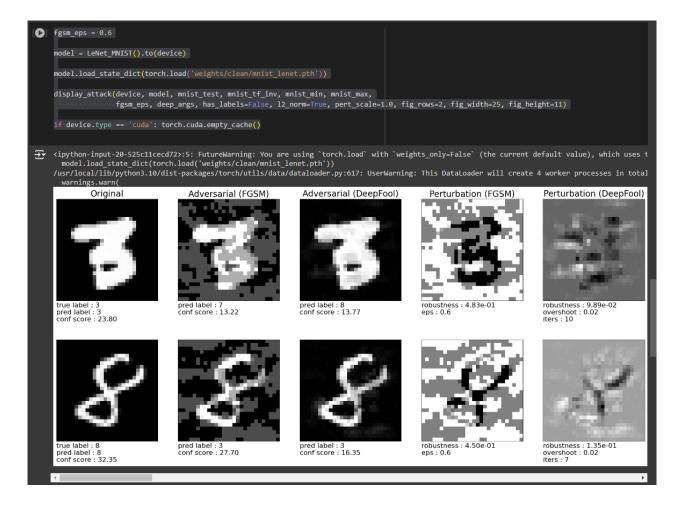
if device.type == 'cuda': torch.cuda.empty_cache()

FGSM Test Error : 91.71%
FGSM Robustness : 8.90e-02
FGSM Time (All Images) : 0.40 s
FGSM Time (All Images) : 0.40 s
FGSM Time (Per Image) : 40.08 us

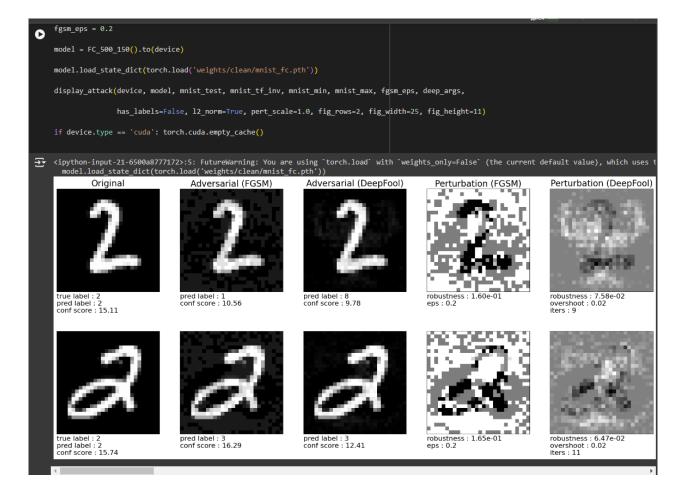
Deepfool Test Error : 87.81%
Deepfool Time (All Images) : 73.27 s
Deepfool Time (Per Image) : 7.33 ms
cipython-input-10-b0414236475d>:5: FutureWarning: You are using `torch.load` with `weights_only=False` (the current default value), which uses t
model.load_state_dict(torch.load('weights/clean/cifar_lenet.pth', map_location-torch.device('cpu')))
```

Выполним оценку атакующих примеров для сетей:

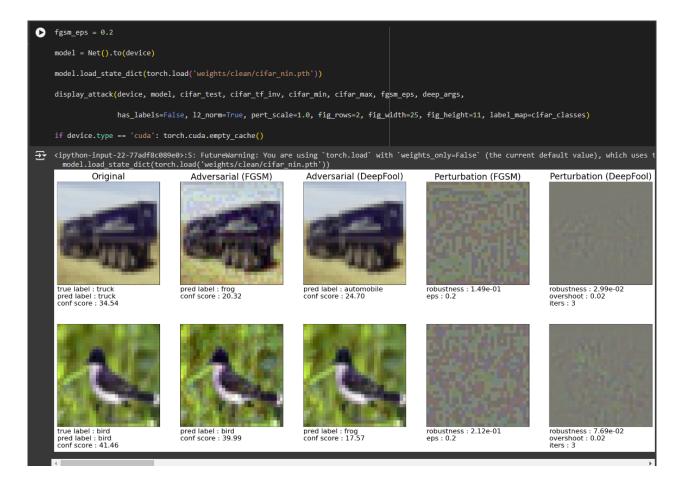
LeNet Ha MNIST



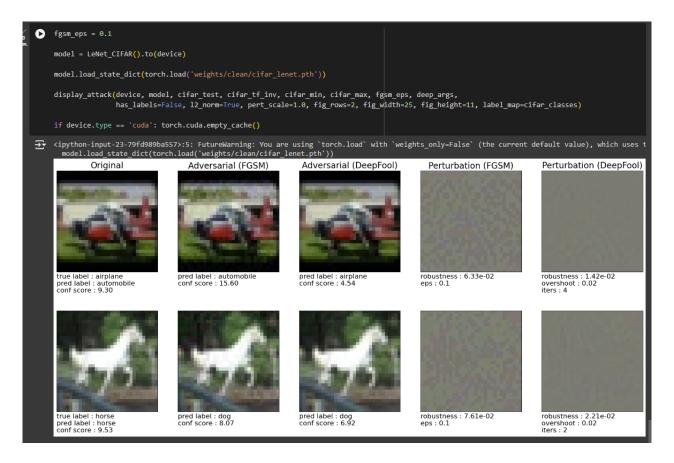
FCNet на MNIST



Network-in-Network на CIFAR

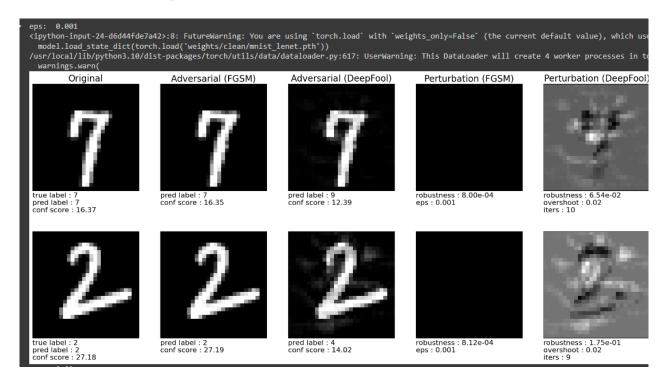


LeNet Ha CIFAR

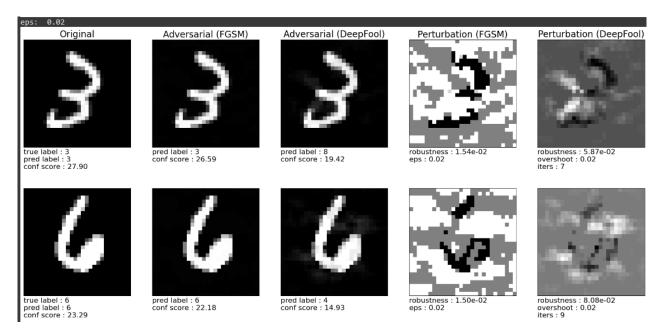


Отразим отличия для $fgsm_eps = (0.001, 0.02, 0.5, 0.9, 10)$

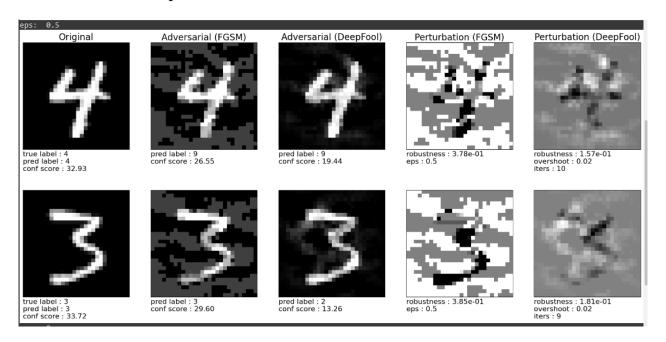
LeNet на MNIST, eps: 0,001



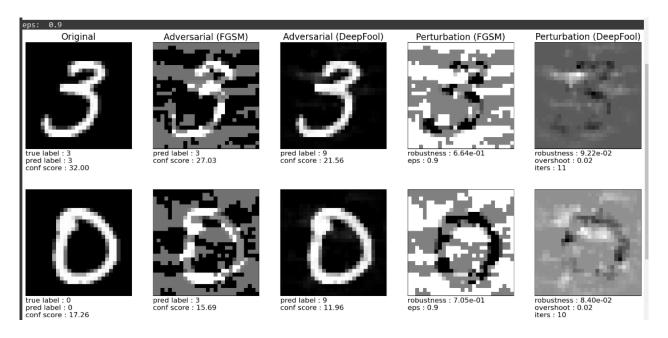
LeNet на MNIST, eps: 0,02



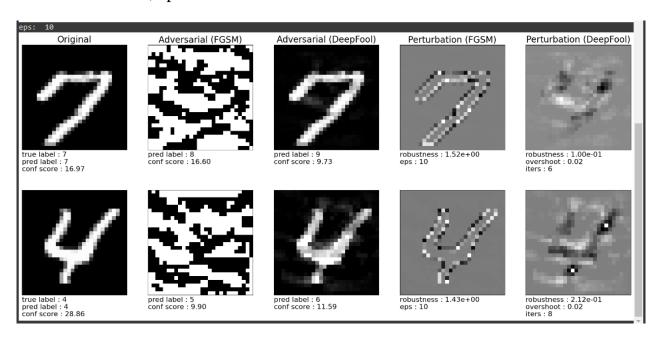
LeNet на MNIST, eps: 0,5



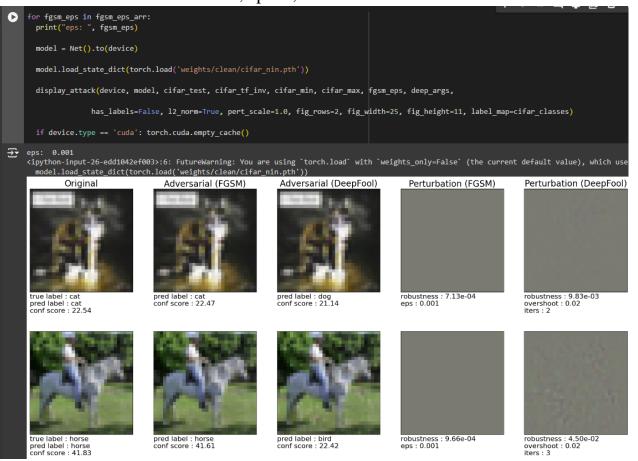
LeNet на MNIST, eps: 0,9



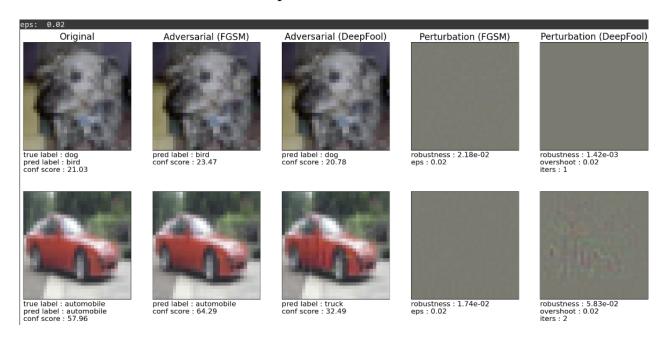
LeNet на MNIST, eps: 10



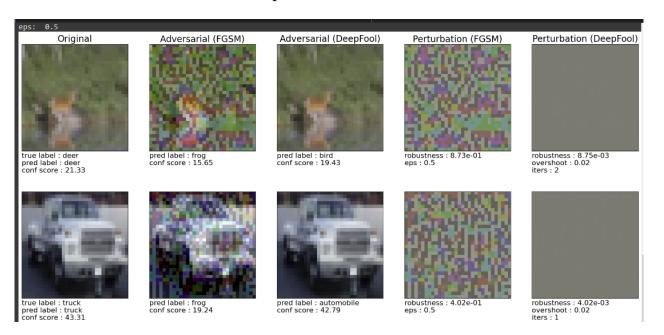
Network-in-Network на CIFAR, eps: 0,001



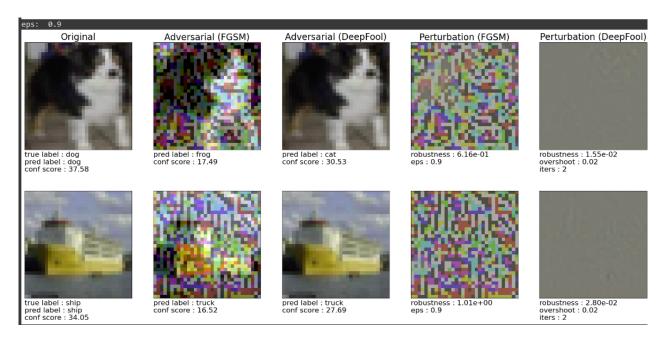
Network-in-Network на CIFAR, eps: 0,02



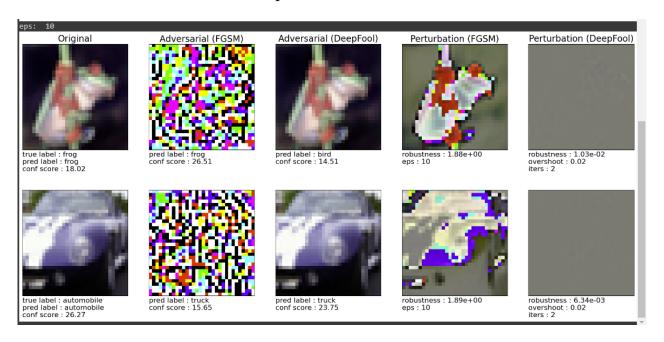
Network-in-Network на CIFAR, eps: 0,05



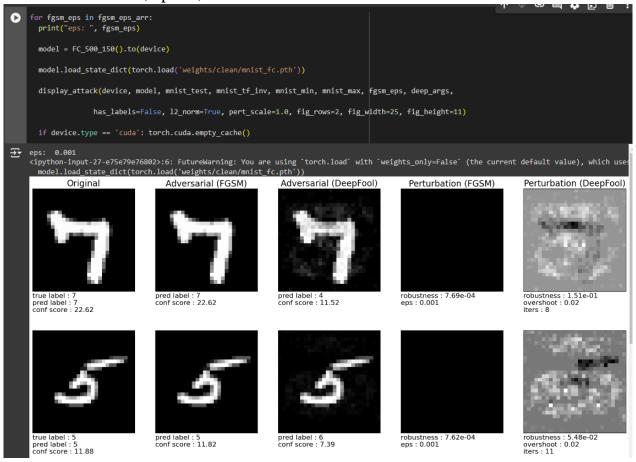
Network-in-Network на CIFAR, eps: 0,9



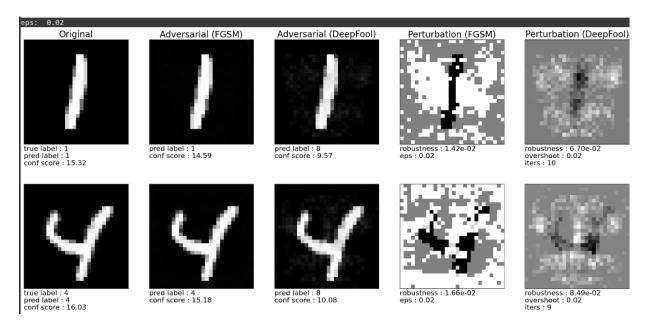
Network-in-Network на CIFAR, eps: 10



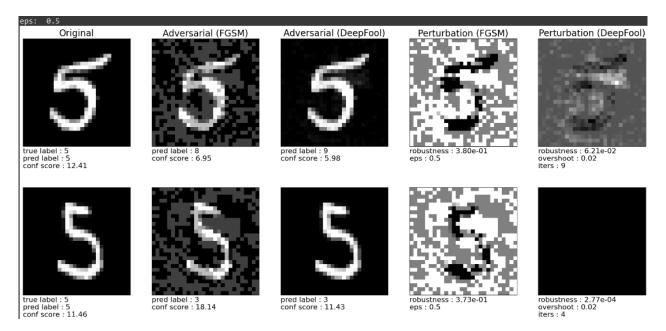
FCNet на MNIST, eps: 0,001



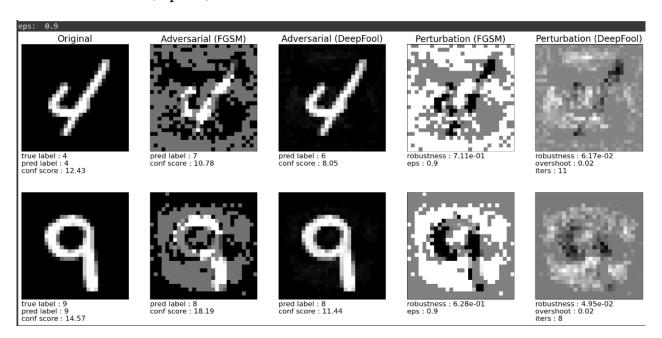
FCNet на MNIST, eps: 0,02



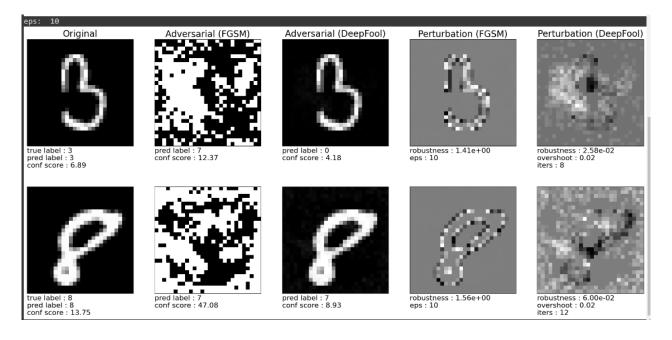
eps: 0,5



FCNet на MNIST, eps: 0,9



eps: 10



Вывод.

Анализируя результаты эксперимента, можно сделать вывод, что с увеличением параметра **fgsm_eps** количество шума на изображениях возрастает. Это явление свидетельствует о том, что изображения становятся более искажёнными, и модель демонстрирует большую подверженность ошибкам в процессе работы.

Иными словами, устойчивость модели к атакам снижается с повышением значения **fgsm_eps**: чем выше этот параметр, тем легче атаке ввести модель в заблуждение и спровоцировать некорректные предсказания.